

PROJET DE FIN D'ÉTUDES

Rapport technique et scientifique

Genomics-to-Therapy

Une plateforme d'intelligence artificielle biomédicale
multimodale :
de la séquence ADN et de l'image histopathologique
à la recommandation de médicaments

Réalisé par : Aziz Amari

Plateforme : architecture microservices, IA et bio-informatique

Remerciements

Nous tenons à exprimer notre gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet. Nous remercions particulièrement notre encadrante et l'ensemble de l'équipe pédagogique pour leurs conseils, ainsi que les contributeurs des bibliothèques scientifiques libres (Biopython, RDKit, PyTorch Geometric, AlphaFold, ESMFold) sans lesquelles ce travail n'aurait pu aboutir.

Résumé

Ce projet propose **Genomics-to-Therapy**, une plateforme d'intelligence artificielle biomédicale qui unifie, au sein d'un même système, deux chaînes de traitement complémentaires : (i) une *piste génomique* qui transforme une séquence d'ADN brute en structure protéique tridimensionnelle puis en candidats-médicaments, et (ii) une *piste histopathologique* qui détecte des mutations à partir d'images de tissus (*Whole Slide Images*). Les deux pistes convergent vers une *couche de fusion* qui réconcilie les indices mutationnels issus des deux modalités afin d'augmenter la confiance des prédictions et de signaler les cas discordants. L'ensemble est exposé à travers une architecture microservices (FastAPI), orchestrée par une passerelle d'API sécurisée (authentification JWT, base PostgreSQL), et piloté par une interface web moderne (Next.js) offrant comptes utilisateurs, tableau de bord, suivi des analyses, résultats et rapports exportables.

La piste génomique et le module de découverte de médicaments sont pleinement fonctionnels et s'appuient sur des outils scientifiques réels (BLAST, UniProt, AlphaFold, ESM-Fold, ChEMBL, RDKit) ainsi que sur un réseau de neurones de graphes (GNN) entraîné. La piste histopathologique est intégrée de bout en bout sous forme de démonstration ; son modèle de prédiction de mutations reste à entraîner sur des données annotées (TCGA).

Mots clés : intelligence artificielle, bio-informatique, découverte de médicaments, réseaux de neurones de graphes, histopathologie, apprentissage multimodal, microservices, AlphaFold.

Table des matières

Introduction générale	1
1 Contexte général et problématique	2
1.1 Contexte biomédical	2
1.2 Problématique	2
1.3 Objectifs	3
1.4 Périmètre et contributions	3
2 Fondements scientifiques et état de l’art	5
2.1 De l’ADN à la protéine	5
2.2 Annotation et similarité de séquences	5
2.3 Prédiction de structure 3D	6
2.4 Découverte de médicaments assistée par IA	6
2.5 Apprentissage profond en histopathologie	6
2.6 Synthèse	6
3 Conception et architecture du système	8
3.1 Architecture en microservices	8
3.2 Acteurs et cas d’utilisation	8
3.3 Modèle de données	9
3.4 Dynamique du pipeline	9
3.5 Couche de fusion multimodale	10
4 Réalisation et choix technologiques	14
4.1 Pile technologique	14
4.2 Organisation du dépôt	14
4.3 Contrats d’interface	15
4.4 Sécurité et gestion des comptes	15

4.5	Déploiement	15
5	Résultats et discussion	17
5.1	État fonctionnel	17
5.2	Vérifications réalisées	17
5.3	Discussion	18
5.3.1	Forces	18
5.3.2	Limites	18
5.3.3	Perspectives	18
	Conclusion générale et perspectives	20
A	Points d'entrée de l'API	21

Table des figures

1.1	Vue d'ensemble du pipeline multimodal : pistes génomique (A) et histopathologique (B), couche de fusion et découverte de médicaments.	4
3.1	Diagramme de composants : interface, passerelle, microservices, bases de données et volume partagé.	9
3.2	Diagramme de cas d'utilisation.	10
3.3	Diagramme de classes / modèle de données de la passerelle.	12
3.4	Diagramme de séquence d'une analyse (orchestration et suivi).	13
4.1	Diagramme de déploiement (Docker Compose).	15

Liste des tableaux

2.1	Outils scientifiques mobilisés par étape.	7
3.1	Composants de la plateforme.	9
4.1	Pile technologique.	14
5.1	Synthèse des vérifications.	18

Liste des acronymes

- **ADN** : Acide DésoxyriboNucléique
- **ADMET** : Absorption, Distribution, Métabolisme, Excrétion, Toxicité
- **API** : *Application Programming Interface*
- **BLAST** : *Basic Local Alignment Search Tool*
- **CNN** : *Convolutional Neural Network* (réseau de neurones convolutif)
- **GC%** : Taux de Guanine–Cytosine
- **GNN** : *Graph Neural Network* (réseau de neurones de graphes)
- **IDP** : *Intrinsically Disordered Protein*
- **JWT** : *JSON Web Token*
- **MIL** : *Multiple Instance Learning*
- **ORF** : *Open Reading Frame* (cadre de lecture ouvert)
- **pLDDT** : *predicted Local Distance Difference Test*
- **REST** : *REpresentational State Transfer*
- **SMILES** : *Simplified Molecular-Input Line-Entry System*
- **TCGA** : *The Cancer Genome Atlas*
- **WSI** : *Whole Slide Image* (lame numérisée entière)
- **XAI** : *eXplainable Artificial Intelligence*

Introduction générale

La médecine de précision ambitionne d’adapter le diagnostic et le traitement aux caractéristiques moléculaires de chaque patient. Or, deux disciplines centrales de cette ambition — l’analyse génomique et l’analyse histopathologique — restent le plus souvent cloisonnées dans des outils et des flux de travail distincts. Par ailleurs, la découverte d’un médicament demeure un processus long (10 à 15 ans) et coûteux, dont les premières étapes (identification d’une cible protéique, criblage de molécules) se prêtent particulièrement bien à l’accélération par l’intelligence artificielle.

Ce projet répond à ce double constat en proposant une plateforme *de bout en bout* qui relie la séquence d’ADN et l’image de tissu à une liste ordonnée de candidats-médicaments, tout en restant scientifiquement rigoureuse à chaque étape (validation des cadres de lecture, scores de confiance structurale, règles de *drug-likeness*). Le présent rapport décrit la problématique, les fondements scientifiques, la conception logicielle, la réalisation et les résultats obtenus.

Le document est organisé comme suit : le **chapitre 1** présente le contexte et la problématique ; le **chapitre 2** expose les fondements scientifiques et l’état de l’art ; le **chapitre 3** détaille la conception et l’architecture du système ; le **chapitre 4** décrit la réalisation technique ; enfin le **chapitre 5** présente les résultats et une discussion critique, avant la conclusion générale.

Chapitre 1

Contexte général et problématique

Introduction

Ce chapitre situe le projet dans son contexte biomédical, énonce la problématique et fixe les objectifs ainsi que le périmètre du travail.

1.1 Contexte biomédical

La cellule traduit l'information génétique (ADN) en protéines, acteurs fonctionnels de la biologie. Une altération de la séquence (mutation) peut modifier la structure et la fonction d'une protéine et favoriser l'apparition de maladies, en particulier les cancers. Cibler une protéine consiste à concevoir une petite molécule capable de se lier à une de ses *poches* pour moduler son activité ; c'est le principe de la majorité des médicaments actuels.

En parallèle, l'examen histopathologique de lames de tissu reste l'étalon-or du diagnostic du cancer. Les techniques d'apprentissage profond permettent aujourd'hui de prédire, à partir de la seule morphologie tissulaire, des caractéristiques moléculaires comme la présence de certaines mutations [1].

1.2 Problématique

Trois difficultés motivent ce travail :

- **Cloisonnement des modalités.** La génomique et l'imagerie sont analysées séparément, alors que leur *recoupement* renforcerait la fiabilité diagnostique.

- **Lenteur et coût de la découverte de médicaments.** Le criblage expérimental de milliers de molécules est onéreux ; une présélection *in silico* de 5 à 10 candidats constitue un gain considérable.
- **Absence d’outil intégré.** Les chercheurs jonglent entre de multiples services en ligne (NCBI, UniProt, AlphaFold, ChEMBL. . .) sans flux unifié, traçable et reproductible.

1.3 Objectifs

L’objectif est de concevoir et réaliser une plateforme unifiée qui :

1. valide une séquence d’ADN et la traduit en séquence protéique ;
2. annote la protéine et prédit (ou récupère) sa structure 3D ;
3. identifie des poches de liaison et propose des candidats-médicaments classés par affinité prédite ;
4. prédit des mutations à partir d’images histopathologiques (piste de démonstration) ;
5. fusionne les indices des deux modalités et produit un rapport exportable ;
6. le tout derrière des comptes utilisateurs, un tableau de bord et une gestion des analyses.

1.4 Périmètre et contributions

La contribution principale de ce travail (en complément d’une première version des microservices de la piste génomique) porte sur : la **réorganisation** du dépôt en mono-dépôt cohérent, la **passerelle d’API** (authentification, persistance, orchestration et fusion), l’**interface web** complète, et l’**intégration** de la piste histopathologique. La figure 1.1 résume la chaîne de traitement multimodale visée.

Conclusion

Le besoin d’un outil intégré, rigoureux et reproductible étant établi, le chapitre suivant présente les briques scientifiques sur lesquelles il s’appuie.




FIGURE 1.1 – Vue d’ensemble du pipeline multimodal : pistes génomique (A) et histopathologique (B), couche de fusion et découverte de médicaments.

Chapitre 2

Fondements scientifiques et état de l'art

Introduction

Ce chapitre rappelle les notions et outils mobilisés par la plateforme, des séquences nucléotidiques aux réseaux de neurones de graphes.

2.1 De l'ADN à la protéine

Une séquence d'ADN valide est composée des nucléotides A, T, C et G. La traduction s'effectue par triplets (codons) à partir d'un codon d'initiation (ATG) et jusqu'à un codon stop, définissant un cadre de lecture ouvert (ORF). La bibliothèque **Biopython** [2] fournit les outils de manipulation et de traduction des séquences, ainsi qu'un accès programmatique aux bases du NCBI.

2.2 Annotation et similarité de séquences

BLAST [3] recherche des protéines homologues connues ; un fort pourcentage d'identité permet d'associer la protéine à une entrée **UniProt** [4], riche en annotations fonctionnelles (domaines, sites actifs, sites de liaison, maladies associées).

2.3 Prédiction de structure 3D

La structure tridimensionnelle conditionne la fonction. **AlphaFold** [5] a révolutionné sa prédiction et met à disposition une base de plus de 200 millions de structures, assorties d'un score de confiance par résidu (pLDDT). Pour les protéines nouvelles, **ESMFold** [6] permet une prédiction rapide sans GPU dédié.

2.4 Découverte de médicaments assistée par IA

Une molécule peut être représentée par une chaîne **SMILES** puis par un *graphe moléculaire* (atomes = nœuds, liaisons = arêtes) à l'aide de **RDKit** [7]. Les **réseaux de neurones de graphes (GNN)** [8,9] apprennent à prédire l'affinité de liaison protéine–ligand. Les candidats sont filtrés par la règle de cinq de Lipinski [10] et sourcés depuis **ChEMBL** [11].

2.5 Apprentissage profond en histopathologie

Les lames numérisées (WSI) sont trop volumineuses pour être traitées d'un bloc ; elles sont découpées en *patches*. Un extracteur de caractéristiques de type **ResNet** [12] encode chaque patch, puis une agrégation par **apprentissage à instances multiples (MIL)** avec attention [13] produit une prédiction au niveau de la lame. La méthode **Grad-CAM** [14] fournit des cartes de chaleur explicatives. Coudray *et al.* [1] ont montré la faisabilité de la prédiction de mutations à partir d'images, en s'appuyant notamment sur les données **TCGA** [15].

2.6 Synthèse

Le tableau 2.1 récapitule les outils par étape. La plateforme se distingue en *chaînant* ces briques et en *recoupant* les deux modalités, là où l'état de l'art les traite isolément.

Conclusion

Ces fondements posés, le chapitre suivant détaille la conception du système qui les intègre.

TABLE 2.1 – Outils scientifiques mobilisés par étape.

Étape	Outil / méthode
Validation & traduction ADN	Biopython, NCBI Entrez
Similarité & annotation	BLAST, UniProt
Structure 3D	AlphaFold DB, ESMFold, RCSB PDB
Poches & candidats	fpocket/P2Rank, ChEMBL, RDKit
Affinité protéine–ligand	GNN (PyTorch Geometric)
Mutation depuis WSI	ResNet50, MIL à attention, Grad-CAM

Chapitre 3

Conception et architecture du système

Introduction

Ce chapitre décrit l’architecture logicielle, les acteurs et cas d’utilisation, le modèle de données, ainsi que la dynamique du pipeline et de la fusion.

3.1 Architecture en microservices

La plateforme adopte une architecture en microservices faiblement couplés, communiquant en REST/JSON. Chaque service scientifique est indépendant, conteneurisé et déployable séparément. Une *passerelle d’API* unique constitue le point d’entrée de l’interface web : elle gère l’authentification, la persistance, l’orchestration du pipeline et la fusion multimodale. La figure 3.1 présente l’organisation des composants.

Le tableau 3.1 liste les services, leurs ports et leur état.

3.2 Acteurs et cas d’utilisation

Deux acteurs interagissent avec la plateforme : le **chercheur** et l’**administrateur** (qui hérite des droits du chercheur). La figure 3.2 présente les cas d’utilisation.




FIGURE 3.1 – Diagramme de composants : interface, passerelle, microservices, bases de données et volume partagé.

TABLE 3.1 – Composants de la plateforme.

Composant	Port	Rôle	État
genomics-validation	8000	Validation et traduction ADN	Fonctionnel
protein-analysis	8001	BLAST, UniProt, repliement, structure 3D	Fonctionnel
drug-discovery	8002	Poches, GNN, classement, ADMET	Fonctionnel
histopathology	8003	WSI → mutation, Grad-CAM	Démonstration
gateway	8080	Auth, orchestration, fusion, rapports	Fonctionnel
frontend	3000	Interface web (Next.js)	Fonctionnel
postgres / redis	5432/6379	Persistance / cache	Fonctionnel

3.3 Modèle de données

La passerelle persiste les entités **User**, **Project**, **Job** et **Report** dans PostgreSQL. Un **Job** matérialise une exécution complète du pipeline et stocke, en colonnes JSON, le résultat de chaque étape ainsi que celui de la fusion. La figure 3.3 en donne le diagramme de classes.

3.4 Dynamique du pipeline

La création d'une analyse renvoie immédiatement un **Job** en statut **pending**; le traitement se poursuit en tâche d'arrière-plan et met à jour l'avancement (**current_step**),

Diagramme de cas d'utilisation - Plateforme Génomique vers Thérapie




FIGURE 3.2 – Diagramme de cas d'utilisation.

que l'interface interroge par *polling*. La figure 3.4 décrit ce déroulement. Chaque étape est encapsulée dans une gestion d'erreurs : l'échec d'une étape (par exemple un service externe indisponible) est consigné sans interrompre le reste du pipeline, garantissant un résultat partiel exploitable.

3.5 Couche de fusion multimodale

La fusion réconcilie, pour chaque gène cible, l'indice *génomique* (piste A) et l'indice *visuel* (piste B). Trois cas se présentent : *concordant* (les deux modalités s'accordent, la confiance augmente), *discordant* (les modalités divergent, le cas est signalé pour revue manuelle) ou *modalité unique*. Un indicateur d'accord global et une mesure de type kappa

sont calculés. L'extrait 3.1 illustre la logique de décision.


```
1 if genomic_signal is not None and visual_signal is not None:
2     if genomic_signal == visual_signal:
3         agreement = "concordant" # confiance renforcee
4         combined = min(1.0, base + 0.15)
5     else:
6         agreement = "discordant" # signale pour revue
7         combined = 0.35
8         flag_for_review = True
9 else:
10    agreement = "single_modality" # une seule modalite disponible
```

Listing 3.1 – Logique de décision de la fusion (extrait simplifié).

Conclusion

La conception étant posée, le chapitre suivant décrit sa réalisation technique.

Modèle de données du Gateway (diagramme de classes / ER)






FIGURE 3.4 – Diagramme de séquence d'une analyse (orchestration et suivi).

Chapitre 4

Réalisation et choix technologiques

Introduction

Ce chapitre présente la pile technologique, l'organisation du dépôt, les contrats d'interface et le déploiement conteneurisé.

4.1 Pile technologique

Le tableau 4.1 récapitule les principales technologies.

TABLE 4.1 – Pile technologique.

Couche	Technologies
Microservices	Python, FastAPI [16], Pydantic, Uvicorn
IA / sciences	PyTorch, PyTorch Geometric, RDKit, Biopython
Passerelle	FastAPI, SQLAlchemy, JWT (pbkdf2), PostgreSQL
Interface	Next.js [17], TypeScript, Tailwind CSS
Cache	Redis
Conteneurisation	Docker, Docker Compose

4.2 Organisation du dépôt

Le projet est structuré en mono-dépôt : `services/` (les quatre microservices), `gateway/` (la passerelle), `frontend/` (l'interface), `packages/contracts/` (les contrats

d'interface partagés en Pydantic) et `docs/` (la documentation et ce rapport). Cette organisation sépare clairement les responsabilités tout en conservant un historique de version unique.

4.3 Contrats d'interface

Pour garantir la cohérence entre services, les schémas de requête/réponse sont centralisés dans le paquet `gtt_contracts`. Ils définissent, entre autres, `ValidationResponse`, `AnalysisResponse` (incluant la structure 3D), `PredictResponse` (candidats-médicaments) et `HistopathologyResponse`.

4.4 Sécurité et gestion des comptes

L'authentification repose sur des jetons JWT signés ; les mots de passe sont hachés (pbkdf2-sha256). Un contrôle d'accès par rôle distingue le chercheur de l'administrateur ; le premier compte créé devient administrateur, et un compte administrateur par défaut est initialisé au démarrage.

4.5 Déploiement

L'ensemble se lance par `docker compose up --build`. La figure 4.1 présente le diagramme de déploiement : huit conteneurs sur un réseau privé, deux volumes (données partagées et base PostgreSQL), et les appels vers les API scientifiques externes.




FIGURE 4.1 – Diagramme de déploiement (Docker Compose).

Conclusion

La réalisation étant décrite, le chapitre suivant en présente les résultats et en discute les limites.

Chapitre 5

Résultats et discussion

Introduction

Ce chapitre rend compte de l'état fonctionnel de la plateforme, des vérifications effectuées, puis discute les limites et les perspectives.

5.1 État fonctionnel

La piste génomique (validation, annotation, structure) et la découverte de médicaments sont opérationnelles et s'appuient sur des services scientifiques réels ainsi qu'un GNN entraîné. La passerelle a été validée de bout en bout (inscription, connexion, contrôle d'accès, projets, orchestration tolérante aux pannes, fusion, génération et export de rapport). L'interface web couvre l'authentification, le tableau de bord, la création et le suivi des analyses, les résultats détaillés et les rapports.

5.2 Vérifications réalisées

Le tableau [5.1](#) synthétise les vérifications. La construction des images Docker (y compris les images lourdes contenant PyTorch, PyTorch Geometric et RDKit) a été menée, et chaque service a fait l'objet d'un contrôle de santé et de démarrage. La passerelle dispose d'un test d'intégration automatisé.

TABLE 5.1 – Synthèse des vérifications.

Élément vérifié	Résultat	Méthode
Authentification & rôles (JWT)	Validé	Test d'intégration
Orchestration du pipeline	Validé	Test (tolérance aux pannes)
Fusion multimodale	Validé	Test unitaire/intégration
Génération & export de rapport	Validé	Export HTML
Construction des images Docker	Validé	<code>docker compose build</code>
Démarrage des services (<i>health</i>)	Validé	Sonde <code>/health</code>
Compilation TypeScript (interface)	Validé	<code>next build</code>

5.3 Discussion

5.3.1 Forces

L'architecture modulaire permet de faire évoluer chaque service indépendamment. Le pipeline tolérant aux pannes fournit toujours un résultat partiel, ce qui est précieux face à des services externes lents ou momentanément indisponibles. La fusion multimodale, même fondée sur des règles, matérialise la valeur ajoutée du recoupement des modalités.

5.3.2 Limites

La principale limite concerne la **piste histopathologique** : son modèle CNN+MIL n'est pas encore entraîné et fonctionne, en l'état, comme une *démonstration* de la chaîne de traitement (extraction de patches, extraction de caractéristiques, agrégation, Grad-CAM). Ses prédictions de mutations ne doivent donc pas être interprétées comme valides. De plus, l'indice génomique utilisé par la fusion est aujourd'hui heuristique : un véritable appel de variants dans la piste A rendrait le recoupement cliniquement significatif. Enfin, plusieurs services dépendent d'API externes, ce qui induit latence et dépendance réseau.

5.3.3 Perspectives

- Entraîner le modèle histopathologique sur des lames annotées (TCGA) et publier les poids, à l'image du GNN de découverte de médicaments.
- Intégrer un appel de variants dans la piste génomique pour une fusion réellement diagnostique.

- Servir les visualisations 3D (py3Dmol) et les cartes Grad-CAM directement dans le navigateur.
- Remplacer la tâche d’arrière-plan par une file de tâches (Celery/RQ) pour la robustesse et la montée en charge, et ajouter des migrations de schéma (Alembic).

Conclusion

La plateforme atteint ses objectifs principaux pour la piste génomique et la découverte de médicaments ; la piste histopathologique fournit une base d’intégration prête à être entraînée.

Conclusion générale et perspectives

Ce projet a abouti à une plateforme d'IA biomédicale multimodale, *Genomics-to-Therapy*, qui relie la séquence d'ADN et l'image histopathologique à la recommandation de candidats-médicaments, derrière une architecture microservices, une passerelle sécurisée et une interface web complète. La piste génomique et le module de découverte de médicaments sont fonctionnels et reposent sur des outils scientifiques reconnus ainsi qu'un réseau de neurones de graphes entraîné ; la piste histopathologique est intégrée de bout en bout et constitue une démonstration prête à être entraînée sur des données annotées.

Au-delà de la réalisation technique, ce travail illustre l'intérêt d'unifier des disciplines historiquement cloisonnées et de recouper plusieurs modalités pour gagner en fiabilité. Les perspectives — entraînement du modèle visuel, appel de variants, visualisations interactives et industrialisation de l'orchestration — dessinent une trajectoire claire vers un outil de recherche pleinement opérationnel au service de la médecine de précision.

Annexe A

Points d'entrée de l'API

La passerelle expose notamment les points d'entrée suivants (préfixe `/api/v1`) :

- `POST /auth/register`, `POST /auth/login`, `GET /auth/me`
- `GET|POST /projects`, `GET|PATCH|DELETE /projects/{id}`
- `POST /jobs`, `GET /jobs`, `GET /jobs/{id}`
- `POST /uploads/wsi`
- `POST /reports`, `GET /reports/{id}/export`
- `GET|PATCH|DELETE /users/{id}` (administrateur)

Bibliographie

- [1] Nicolas Coudray, Paolo Santiago Ocampo, Theodore Sakellaropoulos, et al. Classification and mutation prediction from non-small cell lung cancer histopathology images using deep learning. *Nature Medicine*, 24(10) :1559–1567, 2018.
- [2] Peter JA Cock, Tiago Antao, Jeffrey T Chang, et al. Biopython : freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11) :1422–1423, 2009.
- [3] Stephen F Altschul, Warren Gish, Webb Miller, Eugene W Myers, and David J Lipman. Basic local alignment search tool. *Journal of Molecular Biology*, 215(3) :403–410, 1990.
- [4] The UniProt Consortium. Uniprot : the universal protein knowledgebase in 2023. *Nucleic Acids Research*, 51(D1) :D523–D531, 2023.
- [5] John Jumper, Richard Evans, Alexander Pritzel, et al. Highly accurate protein structure prediction with alphafold. *Nature*, 596(7873) :583–589, 2021.
- [6] Zeming Lin, Halil Akin, Roshan Rao, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, 379(6637) :1123–1130, 2023.
- [7] Greg Landrum et al. Rdkit : Open-source cheminformatics. <https://www.rdkit.org>, 2024.
- [8] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *International Conference on Learning Representations (ICLR)*, 2017.
- [9] Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1263–1272, 2017.
- [10] Christopher A Lipinski, Franco Lombardo, Beryl W Dominy, and Paul J Feeney. Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Advanced Drug Delivery Reviews*, 46(1-3) :3–26, 2001.

- [11] Anna Gaulton, Anne Hersey, Michał Nowotka, et al. The chembl database in 2017. *Nucleic Acids Research*, 45(D1) :D945–D954, 2017.
- [12] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [13] Maximilian Ilse, Jakub Tomczak, and Max Welling. Attention-based deep multiple instance learning. In *International Conference on Machine Learning (ICML)*, pages 2127–2136, 2018.
- [14] Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam : Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.
- [15] John N Weinstein, Eric A Collisson, Gordon B Mills, et al. The cancer genome atlas pan-cancer analysis project. *Nature Genetics*, 45(10) :1113–1120, 2013.
- [16] Sebastián Ramírez. Fastapi. <https://fastapi.tiangolo.com>, 2024.
- [17] Vercel. Next.js : The react framework for the web. <https://nextjs.org>, 2024.