



Université de Carthage

Institut National des Sciences Appliquées et de Technologie (INSAT)

Département Informatique

PROJET PERSONNEL PROFESSIONNEL (PPP)

Plateforme d'IA Biomédicale Multimodale

pour la découverte de médicaments :
de la séquence ADN et de l'image histopathologique
à la recommandation de candidats-médicaments

Réalisé par :

Aziz Amari
Rakia Tsouri
Sinda Ferchichi
Moetez Fradi

Encadré par :

Dr. Hajer Taktak

Classe :

5ème Année Informatique

Année universitaire 2025–2026

À nos familles et à tous ceux qui ont cru en nous,

*À nos enseignants qui ont allumé en nous la flamme
de la curiosité scientifique,*

À la médecine de demain.

Résumé

Ce projet propose une plateforme d'intelligence artificielle biomédicale *de bout en bout* qui unifie deux chaînes de traitement complémentaires : (i) une *piste génomique* (Track A) qui transforme une séquence d'ADN brute en structure protéique tridimensionnelle puis en candidats-médicaments classés par affinité prédite, et (ii) une *piste histopathologique* (Track B) qui prédit la présence de mutations oncogènes à partir d'images de tissus numérisées (*Whole Slide Images*). Les deux pistes convergent vers une *couche de fusion multimodale* qui réconcilie les indices mutationnels issus de chacune, renforçant la confiance des résultats concordants et signalant les cas discordants pour revue médicale.

L'ensemble est exposé à travers une architecture microservices (FastAPI), orchestrée par une passerelle d'API sécurisée (JWT, PostgreSQL) et pilotée par une interface web moderne (Next.js). Le module de découverte de médicaments s'appuie sur un réseau de neurones de graphes (GNN) entraîné sur la base BindingDB, combiné aux filtres pharmacocinétiques de Lipinski et à la détection de poches de liaison par P2Rank.

Mots-clés : intelligence artificielle, bio-informatique, médecine de précision, réseaux de neurones de graphes, histopathologie, apprentissage multimodal, microservices, AlphaFold, ESMFold, Scrum.

Abstract *This project presents an end-to-end biomedical AI platform that unifies a genomic track (DNA sequence $\rightarrow$ 3D protein structure $\rightarrow$ ranked drug candidates) and a histopathological track (Whole Slide Image $\rightarrow$ mutation prediction + Grad-CAM) behind a cross-modal fusion layer. The system is built as a microservices architecture (FastAPI), orchestrated by a secure API gateway (JWT, PostgreSQL) and driven by a modern web interface (Next.js).*

Table des matières

1	Introduction	1
1.1	Contexte biomédical	1
1.1.1	Du génome à la maladie	1
1.1.2	Histopathologie computationnelle	2
1.1.3	Découverte de médicaments	2
1.2	Problématique	2
1.3	Objectifs du projet	2
1.4	Périmètre et contributions	3
1.5	Organisation du rapport	3
2	Contexte scientifique et état de l’art	5
2.1	De l’ADN à la protéine	5
2.2	Annotation et similarité de séquences	5
2.3	Prédiction de structure protéique tridimensionnelle	6
2.4	Détection de poches et découverte de médicaments	6
2.5	Apprentissage profond en histopathologie	6
2.6	Synthèse et positionnement	7
3	Solution proposée	8
3.1	Vue d’ensemble de la solution	8
3.2	Acteurs et diagramme de cas d’utilisation	9
3.3	Spécification des besoins fonctionnels	10
3.4	Spécification des besoins non fonctionnels	11
4	Matériel	12
4.1	Jeux de données utilisés	13
4.2	Modèles d’apprentissage profond	14
4.2.1	Réseau de neurones de graphes : DrugProteinGNN	14

4.2.2	CNN + ABMIL pour l’histopathologie	15
4.3	Outils et frameworks	17
5	Méthodologie	18
5.1	Méthodologie de travail : Scrum	18
5.1.1	Équipe et rôles Scrum	19
5.1.2	Product Backlog	19
5.1.3	Planification des sprints	20
5.2	Méthodologie d’entraînement des modèles	21
5.2.1	Préparation des données	21
5.2.2	Stratégie d’entraînement	22
5.2.3	Métriques d’évaluation	22
6	Architecture du système	24
6.1	Architecture en microservices	24
6.2	Modèle de données	25
6.3	Dynamique du pipeline — Diagramme de séquence	27
6.4	Diagramme d’activité — validation génomique	29
6.5	Couche de fusion multimodale	30
6.6	Diagramme de déploiement	30
6.7	Pipeline d’inférence des modèles	30
6.7.1	Pipeline d’inférence histopathologique	31
6.7.2	Pipeline d’inférence du GNN	33
7	Résultats	36
7.1	État fonctionnel de la plateforme	36
7.2	Résultats d’entraînement du modèle GNN	37
7.3	Captures d’écran de la plateforme	37
7.4	Vérifications et tests réalisés	43
7.5	Discussion	43
7.5.1	Forces de la plateforme	43
7.5.2	Limites	44
	Conclusion générale et perspectives	45

Table des figures

3.1	Vue d'ensemble du pipeline multimodal : pistes génomique (A) et histopathologique (B) convergeant vers la fusion puis la découverte de médicaments.	9
3.2	Diagramme de cas d'utilisation de la plateforme.	10
4.1	Architecture du modèle GNN DrugProteinGNN.	15
4.2	Architecture CNN + Attention-MIL pour la prédiction de mutations à partir d'images WSI.	16
6.1	Diagramme de composants de la plateforme.	25
6.2	Diagramme de classes — modèle de données de la passerelle.	26
6.3	Diagramme de séquence — orchestration complète d'une analyse.	27
6.4	Diagramme d'activité — algorithme de validation génomique.	29
6.5	Diagramme de déploiement Docker Compose.	30
6.6	Pipeline d'inférence du modèle histopathologique.	32
6.7	Pipeline d'inférence du modèle de découverte de médicaments.	34
7.1	Courbes de perte du modèle GNN au cours de l'entraînement.	37
7.2	Écran de connexion à la plateforme.	38
7.3	Tableau de bord du chercheur après connexion.	38
7.4	Formulaire de soumission d'une nouvelle analyse.	39
7.5	Vue détaillée des résultats d'une analyse.	40
7.6	Détail de la couche de fusion croisant Track A et Track B.	41
7.7	Rapport généré pour une analyse complétée.	42

Liste des tableaux

1.1	Répartition des contributions principales.	3
2.1	Outils et méthodes mobilisés par le pipeline.	7
3.1	Besoins non fonctionnels de la plateforme.	11
4.1	Jeux de données mobilisés par la plateforme.	13
4.2	Pile technologique complète du projet.	17
5.1	Rôles Scrum dans l'équipe.	19
5.2	Product Backlog du projet.	19
5.3	Hyperparamètres d'entraînement du GNN.	22
6.1	Composants de la plateforme.	25
7.1	État fonctionnel des composants à la livraison.	36
7.2	Performances du DrugProteinGNN sur l'ensemble de validation.	37
7.3	Synthèse des vérifications.	43

Liste des acronymes

ABMIL	<i>Attention-Based Multiple Instance Learning</i>
ADN	Acide DésoxyriboNucléique
ADMET	Absorption, Distribution, Métabolisme, Excrétion, Toxicité
API	<i>Application Programming Interface</i>
BLAST	<i>Basic Local Alignment Search Tool</i>
CNN	<i>Convolutional Neural Network</i>
GC%	Taux de Guanine-Cytosine
GCN	<i>Graph Convolutional Network</i>
GNN	<i>Graph Neural Network</i>
IDP	<i>Intrinsically Disordered Protein</i>
JWT	<i>JSON Web Token</i>
MIL	<i>Multiple Instance Learning</i>
MSE	<i>Mean Squared Error</i>
ORF	<i>Open Reading Frame</i>
PDB	<i>Protein Data Bank</i>
pIC50	Logarithme négatif de la concentration inhibitrice à 50%
pLDDT	<i>predicted Local Distance Difference Test</i>
PPP	Projet Personnel Professionnel
REST	<i>REpresentational State Transfer</i>
RMSE	<i>Root Mean Squared Error</i>
SMILES	<i>Simplified Molecular-Input Line-Entry System</i>
TCGA	<i>The Cancer Genome Atlas</i>
UML	<i>Unified Modeling Language</i>
WSI	<i>Whole Slide Image</i>
XAI	<i>eXplainable Artificial Intelligence</i>

Chapitre 1

Introduction

Préambule

La médecine de précision ambitionne d’adapter chaque diagnostic et chaque traitement aux caractéristiques moléculaires propres au patient. Au cœur de cette ambition, deux disciplines fondamentales — la **génomique** et l’**histopathologie** — restent pourtant le plus souvent traitées de façon cloisonnée. Par ailleurs, la découverte d’un nouveau médicament représente en moyenne dix à quinze ans de travail et plusieurs milliards de dollars, dont les premières étapes (identification de cibles moléculaires, criblage de composés) se prêtent naturellement à l’accélération par l’intelligence artificielle.

1.1 Contexte biomédical

1.1.1 Du génome à la maladie

L’ADN est le support de l’information génétique de chaque organisme vivant. Il est constitué d’une succession de quatre nucléotides : Adénine (A), Thymine (T), Cytosine (C) et Guanine (G). La machinerie cellulaire lit ces instructions par triplets (codons) pour fabriquer des protéines, véritables acteurs fonctionnels de la biologie. Une **mutation** peut altérer la structure ou la fonction d’une protéine et conduire à un dérèglement cellulaire pouvant aboutir au cancer. Les cancers les plus fréquents sont associés à des mutations récurrentes de gènes suppresseurs de tumeurs comme *TP53*, *IDH1* ou d’oncogènes comme *KRAS*.

1.1.2 Histopathologie computationnelle

L'examen histopathologique consiste à analyser au microscope des coupes de tissus prélevés par biopsie. Cette technique, pilier du diagnostic oncologique depuis plus d'un siècle, est en pleine révolution numérique : les lames sont désormais numérisées en *Whole Slide Images* (WSI) à très haute résolution (parfois supérieure à $100\,000 \times 100\,000$ pixels). Les algorithmes d'apprentissage profond permettent aujourd'hui de détecter des signatures moléculaires invisibles à l'œil humain directement depuis ces images.

1.1.3 Découverte de médicaments

La conception d'un médicament repose sur le principe de la « clé et de la serrure » : une petite molécule (ligand) doit s'insérer dans une *poche de liaison* de la protéine cible pour moduler son activité. L'identification de cette poche et la sélection de molécules candidates constituent les premières étapes du criblage *in silico*.

1.2 Problématique

Trois difficultés majeures motivent ce travail :

- **Cloisonnement des modalités.** L'analyse génomique et l'analyse d'imagerie histologique sont systématiquement traitées séparément, alors que leur *croisement* augmenterait sensiblement la fiabilité diagnostique.
- **Lenteur et coût de la découverte de médicaments.** Le criblage expérimental de milliers de composés est onéreux et long ; une présélection *in silico* par intelligence artificielle peut réduire ce délai de plusieurs années.
- **Absence d'outil intégré et reproductible.** Les chercheurs jonglent entre de multiples services en ligne (NCBI, UniProt, AlphaFold, ChEMBL...) sans flux unifié, tracé et reproductible.

1.3 Objectifs du projet

L'objectif est de concevoir et réaliser une plateforme unifiée capable de :

1. Valider une séquence d'ADN, détecter les cadres de lecture ouverts (ORFs) et les

- traduire en séquences protéiques ;
2. Annoter la protéine (BLAST, UniProt) et récupérer ou prédire sa structure 3D (AlphaFold, ESMFold) ;
 3. Identifier des poches de liaison et proposer un classement de candidats-médicaments par affinité prédite (GNN) ;
 4. Prédire la présence de mutations à partir d’images histopathologiques et générer des cartes explicatives (Grad-CAM) ;
 5. Fusionner les indices des deux modalités pour produire un rapport clinique synthétique exportable ;
 6. Exposer l’ensemble derrière des comptes utilisateurs sécurisés, un tableau de bord et un suivi en temps réel des analyses.

1.4 Périmètre et contributions

Le tableau 1.1 résume les contributions de chaque membre de l’équipe.

TABLE 1.1 – Répartition des contributions principales.

Auteur	Contribution principale
Aziz Amari	Passerelle API (Gateway), authentification, orchestration du pipeline
Rakia Tsouri	Services génomique et analyse protéique (Track A), modèle GNN
Sinda Ferchichi	Service histopathologie (Track B), couche de fusion, interface web
Moetez Fradi	Service découverte de médicaments, entraînement du GNN, rapports

1.5 Organisation du rapport

Le présent rapport est organisé comme suit. Le **chapitre 2** expose les fondements scientifiques et l’état de l’art. Le **chapitre 3** présente la solution proposée à travers ses cas d’utilisation et la spécification de ses besoins. Le **chapitre 4** recense les ressources mobilisées (modèles d’apprentissage profond, jeux de données, outils). Le **chapitre 5**

décrit la méthodologie de développement Scrum ainsi que la méthodologie d'entraînement des modèles. Le **chapitre 6** détaille l'architecture du système, le modèle de données et le pipeline d'inférence des modèles. Le **chapitre 7** présente les résultats expérimentaux et les captures de la plateforme. Une conclusion générale et des perspectives clôturent le document.

Chapitre 2

Contexte scientifique et état de l'art

Introduction

Ce chapitre rappelle les notions clés et les outils de référence mobilisés par la plateforme, des séquences nucléotidiques aux réseaux de neurones de graphes, en passant par la prédiction de structure et l'histopathologie computationnelle.

2.1 De l'ADN à la protéine

Une séquence d'ADN valide est composée des nucléotides A, T, C et G. La traduction s'effectue par triplets (codons) à partir d'un codon d'initiation (ATG) jusqu'à un codon stop (TAA, TAG, TGA), définissant un **cadre de lecture ouvert** (ORF). La bibliothèque **Biopython** [?] fournit les outils de manipulation, de traduction des séquences et d'accès aux bases du NCBI via l'API Entrez.

2.2 Annotation et similarité de séquences

BLAST (*Basic Local Alignment Search Tool*) [?] recherche dans des bases de données de protéines (SwissProt, PDB) des séquences homologues à une séquence requête. Un fort pourcentage d'identité (> 90%) permet d'associer la protéine à une entrée de **UniProt** [?], base qui fournit des annotations fonctionnelles riches : domaines, sites actifs, sites de liaison et maladies associées.

2.3 Prédiction de structure protéique tridimensionnelle

AlphaFold 2 [?] a révolutionné la prédiction de structure en résolvant le problème de repliement des protéines par apprentissage profond. La base **AlphaFold DB** contient plus de 200 millions de structures précalculées, assorties d'un score de confiance par résidu : le **pLDDT** (*predicted Local Distance Difference Test*), interprété comme suit : > 90 = très haute confiance, $70-90$ = confiant, $50-70$ = faible, < 50 = non structuré.

Pour les protéines absentes de la base (séquences nouvelles ou mutées), **ESMFold** [?] de Meta permet une prédiction rapide à partir d'un modèle de langage de protéines (*protein language model*) sans alignements multiples de séquences.

2.4 Détection de poches et découverte de médicaments

Les **poches de liaison** sont des cavités à la surface de la protéine où un ligand peut se fixer. L'outil **P2Rank**, un classifieur d'apprentissage automatique, détecte ces cavités et leur attribue un score de *druggabilité*.

Une molécule chimique peut être représentée par une chaîne **SMILES** (*Simplified Molecular-Input Line-Entry System*) puis convertie en *graphe moléculaire* (atomes = nœuds, liaisons = arêtes) via la bibliothèque **RDKit** [?]. Les **réseaux de neurones de graphes (GNN)** [?] apprennent à prédire l'affinité de liaison protéine-ligand (exprimée en **pIC50**) depuis ces représentations structurées. Les candidats sont issus de **ChEMBL** [?] et filtrés par la **règle des cinq de Lipinski** [?] (poids moléculaire, LogP, donneurs et accepteurs de liaisons hydrogène).

2.5 Apprentissage profond en histopathologie

Les WSI, dont la taille peut dépasser plusieurs gigaoctets, ne peuvent être traitées directement par un CNN. L'approche standard consiste à les découper en **patches** de 256×256 ou 512×512 pixels. Un encodeur pré-entraîné de type **ResNet50** [?] extrait un vecteur de caractéristiques de chaque patch.

L'**apprentissage par instances multiples avec attention (ABMIL)** [?] agrège les représentations de tous les patches d'une lame en une prédiction unique au niveau de la lame

entière. Coudray *et al.* [?] ont montré la faisabilité de la prédiction de mutations (*TP53*, *KRAS*, *STK11*) depuis les seules images histologiques en s’appuyant sur les données du TCGA [?].

La méthode **Grad-CAM** [?] produit des cartes de chaleur expliquant quelles régions de l’image ont le plus contribué à la décision du modèle, satisfaisant ainsi les exigences d’interprétabilité (*XAI*) en contexte médical.

2.6 Synthèse et positionnement

TABLE 2.1 – Outils et méthodes mobilisés par le pipeline.

Étape du pipeline	Outil / méthode clé
Validation & traduction ADN	Biopython, NCBI Entrez
Similarité & annotation	BLAST (SwissProt), UniProt REST API
Structure 3D	AlphaFold DB, ESMFold (Meta), RCSB PDB
Pliabilité protéique	FoldIndex, IUPred2A, hydrophobicité Kyte-Doolittle
Détection de poches	P2Rank
Candidats médicaments	ChEMBL, ZINC15, RDKit (Lipinski)
Affinité protéine–ligand	GNN (PyTorch Geometric, GCNConv)
Analyse WSI	ResNet50, ABMIL, Grad-CAM
Fusion multimodale	Règles de décision + coefficient kappa

La plateforme se distingue de l’état de l’art en *chaînant* ces briques en un flux unique et en *recoupant systématiquement* les deux modalités, là où les travaux existants les traitent isolément.

Conclusion

Les fondements scientifiques posés, le chapitre suivant présente la solution proposée à travers ses cas d’utilisation et la spécification de ses besoins.

Chapitre 3

Solution proposée

Introduction

Ce chapitre présente la solution proposée pour répondre à la problématique identifiée : ses acteurs et cas d'utilisation, sa vision fonctionnelle d'ensemble et la spécification formelle de ses besoins fonctionnels et non fonctionnels.

3.1 Vue d'ensemble de la solution

La solution proposée prend la forme d'une **plateforme web unifiée** articulée autour de deux pistes d'analyse complémentaires et d'une couche de fusion multimodale (figure 3.1). Le chercheur soumet, via une interface web sécurisée, une séquence d'ADN et/ou une image WSI ; le système orchestre alors la chaîne de traitement complète — validation, annotation, structure 3D, prédiction de mutations, fusion et classement de médicaments candidats — et restitue un rapport synthétique exportable.




FIGURE 3.1 – Vue d’ensemble du pipeline multimodal : pistes génomique (A) et histopathologique (B) convergeant vers la fusion puis la découverte de médicaments.

3.2 Acteurs et diagramme de cas d’utilisation

Deux acteurs interagissent avec la plateforme :

- Le **Chercheur** : utilisateur principal, soumet des analyses et consulte les résultats.
- L’**Administrateur** : hérite des droits du chercheur et gère les comptes utilisateurs.

La figure 3.2 présente le diagramme de cas d’utilisation résumant les principales fonc-

tionnalités offertes à chacun.




FIGURE 3.2 – Diagramme de cas d'utilisation de la plateforme.

3.3 Spécification des besoins fonctionnels

Les besoins fonctionnels sont organisés par acteur.

Chercheur

- Créer un compte, s'authentifier et gérer son profil ;
- Créer des projets et y associer des analyses ;
- Soumettre une séquence ADN (texte brut ou FASTA) et/ou un identifiant NCBI ;

- Upload une image WSI pour l’analyse histopathologique ;
- Suivre l’avancement du pipeline étape par étape ;
- Consulter les résultats détaillés : ORFs, annotation, structure 3D, candidats-médicaments, carte Grad-CAM et rapport de fusion ;
- Exporter le rapport final en HTML ou PDF.

Administrateur

- Toutes les fonctionnalités du chercheur ;
- Accéder à l’ensemble des analyses de tous les utilisateurs ;
- Gérer les comptes (activation/désactivation, modification des rôles).

3.4 Spécification des besoins non fonctionnels

TABLE 3.1 – Besoins non fonctionnels de la plateforme.

Catégorie	Exigence
Performance	Chaque service doit répondre en moins de 30 secondes pour une séquence de taille standard (≤ 2000 aa).
Disponibilité	Architecture tolérante aux pannes : la défaillance d’un service externe n’interrompt pas le pipeline.
Sécurité	Authentification JWT signée (HS256), mots de passe hachés (pbkdf2-sha256), contrôle d’accès basé sur les rôles.
Maintenabilité	Architecture microservices : chaque service est déployable et testable indépendamment.
Portabilité	Conteneurisation Docker Compose ; déployable sur toute machine disposant de Docker.
Scalabilité	Architecture prête pour l’ajout d’une file de tâches asynchrones (Celery/RQ).
Interprétabilité	Les prédictions de mutations doivent être accompagnées de cartes Grad-CAM.

Conclusion

La solution étant cadrée par ses cas d’usage et ses exigences, le chapitre suivant recense le matériel scientifique (jeux de données, modèles, outils) mobilisé pour la construire.

Chapitre 4

Matériel

Introduction

Ce chapitre décrit les ressources scientifiques mobilisées par la plateforme : les *jeux de données* qui alimentent l'entraînement et l'inférence, les *modèles d'apprentissage profond* mis en œuvre, et les *outils et frameworks* qui composent la pile technique.

4.1 Jeux de données utilisés

TABLE 4.1 – Jeux de données mobilisés par la plateforme.

Jeu de données	Utilisation	Description
BindingDB	Entraînement GNN	Base d'affinités protéine–ligand mesurées expérimentalement ($\sim 2,8$ M interactions, $\sim 1,2$ M ligands, $\sim 8\,800$ cibles). Source des couples (séquence protéique, SMILES, pIC50) pour l'entraînement de DrugProteinGNN .
PDBbind v2020	Structures protéine–ligand	Sous-ensemble <i>refined</i> ($\sim 5\,000$ complexes) utilisé pour la construction des graphes protéiques d'entraînement.
TCGA-LUAD / BRCA / LGG	Inférence Track B	Lames numérisées (WSI) du <i>The Cancer Genome Atlas</i> : adénocarcinome pulmonaire, cancer du sein, gliome de bas grade. Données disponibles pour un futur entraînement supervisé du modèle CNN+MIL.
ChEMBL v32	Candidats médicaments	Plus de 2,3 M de composés bioactifs avec leurs SMILES, leurs cibles et leurs activités. Source des candidats lors de l'inférence.
ZINC15	Candidats médicaments	230 M de molécules <i>drug-like</i> disponibles commercialement. Sous-ensemble <i>FDA-approved</i> utilisé en complément de ChEMBL.
AlphaFold DB	Structures 3D	Plus de 200 M de structures protéiques prédites avec score pLDDT par résidu. Source primaire des structures pour la découverte de médicaments.
RCSB PDB	Structures 3D	Structures expérimentales (rayons X, cryo-EM) utilisées en complément lorsque pertinentes.
UniProt	Annotations	Annotations fonctionnelles des protéines (domaines, sites actifs/liaison, maladies associées).
NCBI Entrez	Séquences ADN	Récupération automatique de séquences à partir d'un identifiant (<i>e.g.</i> NM_000546 pour TP53).

4.2 Modèles d'apprentissage profond

La plateforme mobilise deux familles de modèles d'apprentissage profond, chacune adaptée à une modalité.

4.2.1 Réseau de neurones de graphes : DrugProteinGNN

Le modèle DrugProteinGNN prédit l'affinité de liaison protéine–ligand (exprimée en pIC50) à partir de deux graphes en entrée : le graphe de la *poche protéique* (résidus = nœuds, contacts spatiaux = arêtes) et le graphe de la *molécule candidate* (atomes = nœuds, liaisons = arêtes). Chaque branche est composée de deux couches **GCNConv** suivies d'un *global mean pool*, et les deux représentations latentes sont concaténées puis passées à un perceptron multi-couches qui régresse le score pIC50 (figure 4.1).

DrugProteinGNN – Architecture du modèle




FIGURE 4.1 – Architecture du modèle GNN DrugProteinGNN.

4.2.2 CNN + ABMIL pour l’histopathologie

Pour la piste B, la lame WSI est découpée en patches de 256×256 pixels. Chaque patch est encodé par un **ResNet50** [?] (couche `layer4`) en un vecteur de caractéristiques de dimension 2048. Les vecteurs des patches d’une même lame sont ensuite agrégés par un module **Attention-based MIL (ABMIL)** [?] qui calcule des poids d’attention par patch, produit une représentation au niveau de la lame, puis prédit la présence de chaque mutation cible (figure 4.2). La méthode **Grad-CAM** [?] produit une carte de chaleur explicative pour le patch le plus discriminant.




FIGURE 4.2 – Architecture CNN + Attention-MIL pour la prédiction de mutations à partir d'images WSI.

4.3 Outils et frameworks

TABLE 4.2 – Pile technologique complète du projet.

Couche	Technologies
Microservices	Python 3.11, FastAPI, Pydantic v2, Uvicorn
Sciences / IA	PyTorch 2, PyTorch Geometric, RDKit, Biopython, torchvision
Passerelle	FastAPI, SQLAlchemy 2, JWT (python-jose), pbkdf2-sha256
Interface	Next.js 14, TypeScript, Tailwind CSS, React 18
Visualisation 3D	3Dmol.js (protéine + ligand côté client)
Base de données	PostgreSQL 16, Redis 7 (alpine)
Conteneurisation	Docker 24, Docker Compose v2
Explicabilité	Grad-CAM (torchvision hooks)
Tests	pytest, pytest-asyncio, respx, httpx ASGI

Conclusion

Le matériel scientifique étant inventorié, le chapitre suivant détaille la méthodologie de développement et la méthodologie d'entraînement des modèles.

Chapitre 5

Méthodologie

Introduction

Ce chapitre décrit deux méthodologies complémentaires : la *méthodologie de travail* adoptée pour piloter le projet (Scrum) et la *méthodologie d'entraînement* des modèles d'apprentissage profond.

5.1 Méthodologie de travail : Scrum

Face à la nature exploratoire du projet — à la croisée de la bio-informatique et de l'intelligence artificielle — une approche **Agile** était plus adaptée qu'une méthode en cascade. Les exigences scientifiques évoluent au fil des expérimentations, et chaque résultat intermédiaire alimente les décisions de conception de l'étape suivante.

Scrum a été retenu pour les raisons suivantes :

- Organisation en **sprints courts** (2 semaines) avec livraison incrémentale de fonctionnalités ;
- **Backlog priorisé** permettant de se concentrer sur les composants à plus forte valeur ajoutée scientifique ;
- **Réunions de revue** en fin de sprint pour valider chaque microservice avec l'encadrante ;
- **Adaptabilité** aux découvertes techniques (indisponibilité d'une API externe, performances insuffisantes d'un modèle).

5.1.1 Équipe et rôles Scrum

TABLE 5.1 – Rôles Scrum dans l'équipe.

Rôle	Responsable
Product Owner	Dr. Hajer Taktak
Scrum Master	Aziz Amari
Équipe de développement	Aziz Amari, Rakia Tsouri, Sinda Ferchichi, Moetez Fradi

5.1.2 Product Backlog

TABLE 5.2 – Product Backlog du projet.

ID	User Story	Épopée	Prio.	Pts
US01	Soumettre une séquence ADN et obtenir ses ORFs traduits.	Track A	Haute	8
US02	Récupération automatique d'une séquence par identifiant NCBI.	Track A	Haute	5
US03	Identification BLAST + annotations UniProt.	Track A	Haute	8
US04	Structure 3D de la protéine (AlphaFold ou ESMFold).	Track A	Haute	13
US05	Détection des poches de liaison.	Drug Disco- very	Haute	8
US06	Classement des 10 meilleurs candidats-médicaments.	Drug Disco- very	Haute	13
US07	Propriétés ADMET de chaque candidat.	Drug Disco- very	Moyenne	5
US08	Upload WSI et prédiction de mutation.	Track B	Haute	13
US09	Carte Grad-CAM superposée.	Track B	Haute	8
US10	Rapport de fusion croisant les modalités.	Fusion	Haute	8

Suite à la page suivante...

(suite du tableau 5.2)

ID	User Story	Épopée	Prio.	Pts
US11	Inscription et connexion sécurisées.	Auth	Haute	5
US12	Organisation des analyses par projet.	Gestion	Moyenne	5
US13	Suivi en temps réel d'une analyse.	Gestion	Haute	5
US14	Export d'un rapport HTML/PDF.	Rapport	Moyenne	5
US15	Administration des comptes utilisateurs.	Admin	Basse	3
US16	Visualisation 3D moléculaire en navigateur.	Visualisation	Moyenne	8

5.1.3 Planification des sprints

Le projet a été découpé en **4 sprints** de deux semaines, soit 8 semaines de développement.

Sprint 1 — Infrastructure & Track A (1) — Semaines 1–2

Objectif : Infrastructure Docker et service de validation génomique.

ID	Tâche	Statut
US11	Monorepo, Docker Compose (Redis)	Terminé
US01	genomics_validation : ORFs, traduction	Terminé
US02	API NCBI Entrez + cache Redis	Terminé
	Tests unitaires logique ADN	Terminé

Vélocité réalisée : 18 points

Sprint 2 — Track A (2) & Drug Discovery — Semaines 3–4

Objectif : Analyse protéique et découverte de médicaments avec GNN.

ID	Tâche	Statut
US03	protein_analysis : BLAST, UniProt, fold check	Terminé
US04	AlphaFold DB + ESMFold API	Terminé
US05	drug_discovery : détection de poches P2Rank	Terminé
US06	Entraînement GNN (BindingDB) et inférence	Terminé
US07	ADMET (RDKit), Lipinski, classement Top 10	Terminé

Vélocité réalisée : 47 points

Sprint 3 — Track B**Objectif :** Piste histopathologique, passerelle d'API, couche de fusion.

ID	Tâche	Statut
US08	histopathology : patches, CNN, MIL	Terminé
US09	Génération des cartes Grad-CAM	Terminé
US10	Couche de fusion multimodale	Terminé
US11	Gateway : JWT, PostgreSQL, rôles	Terminé
US12	Gestion projets et jobs (CRUD)	Terminé
US13	Orchestrateur du pipeline	Terminé
US14	Générateur de rapports HTML	Terminé

Vélocité réalisée : 49 points**Sprint 4 — Interface & Finalisation — Semaines 7–8****Objectif :** Interface Next.js, visualisations, documentation.

ID	Tâche	Statut
US11	Pages Inscription/Connexion + tokens	Terminé
US12	Tableau de bord des projets	Terminé
US13	Suivi en temps réel (polling)	Terminé
US16	Visualisation 3D moléculaire (3Dmol.js)	Terminé
US14	Export rapport HTML/PDF	Terminé
US15	Interface d'administration	Terminé
	Tests d'intégration end-to-end + déploiement	Terminé
	Docker	

Vélocité réalisée : 31 points

5.2 Méthodologie d'entraînement des modèles

Cette section décrit la procédure d'entraînement adoptée pour le modèle DrugProteinGNN. La même grille générale serait appliquée au modèle CNN+ABMIL pour la piste histopathologique une fois les données TCGA annotées disponibles.

5.2.1 Préparation des données

Les couples (protéine, ligand, pIC50) sont extraits de BindingDB. Les ligands de SMILES invalides ou de poids moléculaire > 900 Da sont écartés. Les structures pro-

téiques correspondantes sont récupérées depuis le sous-ensemble *refined* de PDBbind. Pour chaque couple, deux graphes sont construits :

- **Graphe protéique** : les résidus de la poche (CA atoms) sont les nœuds (25 dimensions de *features* encodant le type d'acide aminé, l'hydrophobicité et le score d'accessibilité au solvant). Une arête est créée entre deux résidus si la distance entre leurs C α est inférieure à 8 Å.
- **Graphe moléculaire** : les atomes du ligand sont les nœuds (5 dimensions de *features* : numéro atomique, degré, charge formelle, hybridation, aromaticité). Les liaisons covalentes sont les arêtes.

L'ensemble final compte $\sim 5\,000$ couples. La cible pIC50 est conservée telle quelle (régression).

5.2.2 Stratégie d'entraînement

TABLE 5.3 – Hyperparamètres d'entraînement du GNN.

Paramètre	Valeur
Découpe train/validation	80% / 20% (aléatoire avec graine fixée)
Taille de lot (<i>batch size</i>)	128
Optimiseur	Adam, <i>learning rate</i> = 10^{-3}
Fonction de perte	MSE sur pIC50
Nombre d'époques	50 (point de sauvegarde tous les 5 époques)
Dropout (couche de fusion)	0,2
Périphérique	CUDA si disponible, CPU sinon

L'entraînement est piloté par le script `services/drug_discovery/ml/train.py`. Un *checkpoint* est sauvegardé toutes les 5 époques pour permettre la reprise après interruption.

5.2.3 Métriques d'évaluation

Les métriques retenues pour le GNN (régression) sont :

- **RMSE** (*Root Mean Squared Error*) sur le pIC50 ;

- **MAE** (*Mean Absolute Error*) ;
- **R²** (*coefficient of determination*) ;
- **Spearman ρ** pour la corrélation de rang (utile au criblage).

Pour le modèle CNN+ABMIL (classification), les métriques cibles sont AUC-ROC, F1-score, exactitude (*accuracy*) et matrice de confusion. La cible visée est AUC-ROC $> 0,80$ conformément à la référence [?].

Conclusion

La méthodologie de développement et d'entraînement étant posée, le chapitre suivant détaille l'architecture du système et le pipeline d'inférence des modèles.

Chapitre 6

Architecture du système

Introduction

Ce chapitre détaille l’architecture logicielle de la plateforme : la *décomposition en microservices*, le *modèle de données* de la passerelle, la *dynamique du pipeline*, la *couche de fusion multimodale*, le *déploiement* et enfin le *pipeline d’inférence* des modèles d’apprentissage profond.

6.1 Architecture en microservices

La plateforme adopte une architecture en **microservices faiblement couplés**, communiquant en REST/JSON sur un réseau Docker privé. Chaque service scientifique est indépendant, conteneurisé et déployable séparément. Un seul point d’entrée — la **passerelle d’API** (Gateway) — concentre l’authentification, la persistance, l’orchestration du pipeline et la fusion multimodale (figure 6.1).





FIGURE 6.1 – Diagramme de composants de la plateforme.

TABLE 6.1 – Composants de la plateforme.

Composant	Port	Rôle	État
genomics-validation	8000	Validation, ORFs, traduction ADN	Opérationnel
protein-analysis	8001	BLAST, UniProt, repliement, structure 3D	Opérationnel
drug-discovery	8002	Poches, GNN, classement, ADMET	Opérationnel
histopathology	8003	WSI → mutation, Grad-CAM	Opérationnel
gateway	8080	Auth, orchestration, fusion, rapports	Opérationnel
frontend	3000	Interface web (Next.js)	Opérationnel
PostgreSQL / Redis	5432/6379	Persistance / cache	Opérationnel

6.2 Modèle de données

La passerelle persiste quatre entités principales dans PostgreSQL. Un Job matérialise une exécution complète du pipeline et stocke, en colonnes JSON, le résultat de chaque étape (figure 6.2).

Modèle de données du Gateway (diagramme de classes / ER)

6.3 Dynamique du pipeline — Diagramme de séquence





FIGURE 6.3 – Diagramme de séquence — orchestration complète d'une analyse.

6.4 Diagramme d'activité — validation génomique



6.5 Couche de fusion multimodale

La fusion compare, pour chaque gène cible, l'indice génomique (piste A) et l'indice visuel (piste B). Trois cas sont possibles :

- **Concordant** : les deux modalités s'accordent — le score de confiance combiné est augmenté (+0.15) pour récompenser la convergence.
- **Discordant** : les modalités divergent — le cas est signalé pour revue manuelle (`flag_for_review = True`), avec un score réduit (0.35).
- **Modalité unique** : une seule piste a produit un signal — le score de la modalité disponible est retenu.

Un indicateur global d'accord et une approximation du **coefficient kappa** (mesure de Cohen) sont calculés sur l'ensemble des gènes évalués et inclus dans le rapport final, permettant au chercheur d'apprécier d'un seul coup d'œil la cohérence interne des prédictions multimodales.

6.6 Diagramme de déploiement




FIGURE 6.5 – Diagramme de déploiement Docker Compose.

6.7 Pipeline d'inférence des modèles

Cette section détaille les pipelines d'inférence des deux modèles d'apprentissage profond intégrés à la plateforme.

6.7.1 Pipeline d'inférence histopathologique

L'inférence pour la piste B suit cinq étapes successives, illustrées figure 6.6 :

1. **Extraction de patches** : découpage de la WSI en tuiles 256×256 , filtrage par seuillage d'Otsu pour ne garder que les patches contenant du tissu et normalisation de la coloration (méthode de Macenko).
2. **Extraction de caractéristiques** : encodage de chaque patch par un ResNet50 (*features* de la couche `layer4`, vecteur de dimension 2048).
3. **Agrégation par attention (ABMIL)** : calcul d'un poids d'attention par patch, somme pondérée des *features*, production d'un *embedding* de lame.
4. **Prédiction par gène** : une tête de classification dédiée par gène cible (TP53, IDH1, KRAS) produit une probabilité de mutation.
5. **Grad-CAM** : génération d'une carte de chaleur sur le patch de plus forte attention pour expliquer la prédiction.

Pipeline d'inférence histopathologique (Track B)





FIGURE 6.6 – Pipeline d'inférence du modèle histopathologique.

6.7.2 Pipeline d'inférence du GNN

L'inférence du GNN combine la structure 3D de la protéine et chaque molécule candidate (figure 6.7) :

1. **Détection de poche** (P2Rank) sur le fichier PDB pour identifier la cavité de liaison la plus druggable.
2. **Graphe protéique** construit à partir des résidus de la poche : nœuds = $C\alpha$, arêtes = contacts à $<8 \text{ \AA}$.
3. **Graphe ligand** construit à partir du SMILES via RDKit : nœuds = atomes, arêtes = liaisons covalentes.
4. **Encodage parallèle** : deux GCNs encodent respectivement les deux graphes ; un *global mean pool* produit un *embedding* par graphe.
5. **Fusion et régression** : concaténation des *embeddings*, passage par un MLP, prédiction du score pIC50.
6. **Classement Top 10** : filtrage Lipinski, calcul des métriques ADMET (RDKit), tri des candidats par score décroissant.

Pipeline d'inférence — Découverte de médicaments



Conclusion

L'architecture étant décrite dans ses dimensions statique (composants, données) et dynamique (séquence, activité, inférence), le chapitre suivant présente les résultats obtenus.

Chapitre 7

Résultats

Introduction

Ce chapitre rend compte des résultats expérimentaux : l'état fonctionnel de la plateforme à l'issue des 4 sprints, les performances mesurées du modèle GNN entraîné, et des captures d'écran illustrant l'interface livrée au chercheur.

7.1 État fonctionnel de la plateforme

TABLE 7.1 – État fonctionnel des composants à la livraison.

Composant	État	Remarque
Validation génomique	Complet	Tests unitaires passés
Analyse protéique	Complet	BLAST, UniProt, AlphaFold/ESMFold
Découverte médicaments	Complet	GNN entraîné (BindingDB)
Histopathologie	Complet	Pipeline CNN+MIL intégré
Passerelle / Auth	Complet	JWT, rôles, PostgreSQL
Orchestration pipeline	Complet	Tolérant aux pannes
Couche de fusion	Complet	Concordance + kappa
Interface web	Complet	Tous les écrans fonctionnels
Export rapport HTML	Complet	Généré côté gateway

7.2 Résultats d'entraînement du modèle GNN

Le modèle DrugProteinGNN a été entraîné sur le sous-ensemble *refined* de PDBbind v2020 enrichi des affinités BindingDB. La figure 7.1 présente l'évolution des fonctions de perte d'entraînement et de validation au fil des 50 époques. Les métriques finales sur l'ensemble de validation sont synthétisées dans le tableau 7.2.




FIGURE 7.1 – Courbes de perte du modèle GNN au cours de l'entraînement.

TABLE 7.2 – Performances du DrugProteinGNN sur l'ensemble de validation.

Métrique	Valeur
RMSE (pIC50)	1,12
MAE (pIC50)	0,86
R^2	0,68
Spearman ρ	0,73
Perte finale (MSE)	1,25
Taille du modèle	119 425 paramètres (~471 KB)
Temps d'entraînement	~38 min (CPU) / ~7 min (GPU)

7.3 Captures d'écran de la plateforme

Cette section présente l'interface livrée au chercheur. Les captures sont prises avec les comptes de démonstration seed-és automatiquement (`admin@medconnect.dev`,

researcher@medconnect.dev).




FIGURE 7.2 – Écran de connexion à la plateforme.

The dashboard for the Genomics-Therapy AI Platform. The left sidebar contains a menu with 'Dashboard', 'Analyses', 'Projects', 'Reports', and 'Settings'. The main area shows a 'Welcome, Demo' message and a summary of analyses. The summary includes four cards: 'TOTAL ANALYSES' (6), 'COMPLETED' (6, 100% success rate), 'PROJECTS' (4), and 'REPORTS' (4). Below the summary is a section for 'Recent analyses' with a table of pipeline runs.

NAME	STATUS	STEP	GENE	CREATED	ACTIONS
aaaa	Completed	done	-	Jun 1, 2026, 12:55 PM	Open
IDH1 R132H · glioma case GB-007	Completed	done	NM_005896.4	May 31, 2026, 12:55 PM	Open
EGFR L858R · NSCLC-114	Completed	done	NM_005228.5	May 30, 2026, 12:55 PM	Open
BRCA1 hereditary screen · BC-072	Completed	done	NM_007294.4	May 29, 2026, 12:55 PM	Open
TP53 patient sample · LUAD-A3F1	Completed	done	NM_000546.6	May 28, 2026, 12:55 PM	Open
TP53 reference analysis · LUAD	Completed	done	NM_000546.6	May 26, 2026, 12:55 PM	Open

FIGURE 7.3 – Tableau de bord du chercheur après connexion.

The screenshot shows the 'New analysis' form in the Genomics-to-Therapy AI Platform. The interface includes a sidebar with navigation links: Dashboard, Analyses (selected), Projects, Reports, and Settings. The top right shows a 'New analysis' button and a user profile for 'researcher@medconnect...'. The form itself is titled 'New analysis' and has a subtitle 'Configure inputs for an end-to-end genomics-to-therapy pipeline run.'.

Basics
Name and optional project.

Analysis name * Project

Genomics input
Provide a DNA / FASTA sequence, or reference an existing gene.

DNA sequence

Paste raw nucleotides or a FASTA record. ACGT/N accepted.

Histopathology input (Track B)
Optional whole-slide image for mutation prediction.

No slide handy? [Download a sample tissue image](#) and upload it below.

svs, ihf, ndpi or standard image formats

FIGURE 7.4 – Formulaire de soumission d'une nouvelle analyse.




FIGURE 7.5 – Vue détaillée des résultats d’une analyse.




FIGURE 7.6 – Détail de la couche de fusion croisant Track A et Track B.




FIGURE 7.7 – Rapport généré pour une analyse complétée.

7.4 Vérifications et tests réalisés

TABLE 7.3 – Synthèse des vérifications.

Élément vérifié	Résultat	Méthode
Tests unitaires génomique (ORFs, GC%, validation)	Passé	pytest
Tests unitaires fold check (hydrophobicité)	Passé	pytest
Test intégration API protein service	Passé	pytest-asyncio + respx
Authentification et RBAC (JWT)	Validé	Test intégration
Orchestration pipeline (tolérance aux pannes)	Validé	Test intégration
Fusion multimodale (3 scénarios)	Validé	Test unitaire
Génération de rapport HTML	Validé	Test manuel
Construction images Docker	Validé	<code>docker compose build</code>
Démarrage des services (<code>/health</code>)	Validé	Sonde HTTP
Compilation TypeScript (interface)	Validé	<code>next build</code>

7.5 Discussion

7.5.1 Forces de la plateforme

- **Architecture modulaire** : chaque microservice est indépendant, testable et déployable séparément.
- **Tolérance aux pannes** : le pipeline encapsule chaque étape dans un bloc `try/except` ; la défaillance d'une API externe est consignée sans interrompre le reste du pipeline.
- **Recoupement multimodal** : la couche de fusion matérialise concrètement l'intérêt de croiser deux modalités complémentaires pour renforcer la confiance diagnostique.
- **Outils scientifiques réels** : le pipeline s'appuie sur les bases de données et algorithmes de référence (BLAST, UniProt, AlphaFold, ChEMBL).

7.5.2 Limites

L'indice génomique utilisé par la couche de fusion repose actuellement sur une heuristique (annotation de maladie dans UniProt) plutôt que sur un véritable appel de variants ; l'intégration d'un outil comme GATK ou DeepVariant en amont rendrait la fusion cliniquement plus significative. Par ailleurs, les services scientifiques dépendent d'API externes (NCBI, BLAST, AlphaFold) dont la latence varie ; un cache disque global réduirait significativement la durée des analyses récurrentes.

Conclusion

La plateforme atteint ses objectifs principaux et offre un outil intégré, ergonomique et reproductible pour la recherche en oncologie computationnelle.

Conclusion générale et perspectives

Ce projet personnel professionnel a abouti à une **plateforme d'IA biomédicale multimodale** qui relie, dans un outil unifié, la séquence d'ADN et l'image histopathologique à la recommandation ordonnée de candidats-médicaments. La plateforme est structurée en huit composants conteneurisés, orchestrés par une passerelle d'API sécurisée et pilotés par une interface web moderne.

La piste génomique (validation ADN, annotation, structure 3D, découverte de médicaments) s'appuie sur des services et bases de données scientifiques reconnus mondialement (BLAST, UniProt, AlphaFold, ESMFold, ChEMBL) ainsi que sur un réseau de neurones de graphes entraîné. La piste histopathologique constitue une chaîne de traitement complète (extraction de patches, encodage ResNet50, agrégation par attention, Grad-CAM) intégrée de bout en bout dans le pipeline.

La méthodologie **Scrum**, organisée en quatre sprints de deux semaines, a permis de livrer incrémentalement les fonctionnalités et de s'adapter aux contraintes techniques rencontrées.

Perspectives

- **Entraînement supervisé** du modèle CNN+ABMIL sur les lames annotées du TCGA et publication des poids ;
- **Appel de variants** dans la piste génomique (GATK, DeepVariant) pour rendre la couche de fusion cliniquement significative ;
- **File de tâches asynchrones** (Celery / RQ) pour la durabilité, les reprises sur erreur et la montée en charge ;
- **Visualisations interactives** : serveur de fichiers statiques pour les structures 3D et les cartes Grad-CAM ;
- **Migrations de schéma** (Alembic) pour une évolution contrôlée de la base PostgreSQL.

Au-delà de la réalisation technique, ce travail démontre la faisabilité et l'intérêt de croiser la génomique et l'imagerie computationnelle pour renforcer la fiabilité diagnostique, et ouvre la voie à un outil de recherche pleinement opérationnel au service de la médecine de précision.